Atomické operace a redukce PCG – Paralelní výpočty na GPU Cvičení 4, 2022/2023

Jirka Jaroš

Vysoké učení technické v Brně, Fakulta informačních technologií Božetěchova 1/2, 612 66 Brno - Královo Pole jarosjir@fit.vutbr.cz



I Interaktivní práce CVT



Export cest ke CUDA

```
export PATH=$PATH:/usr/local/share/cuda-11.4/bin
```

```
export LD_LIBRARY_PATH=$LD_LIBRARY_PATH:/usr/local/share/cuda-
11.4/bin:/usr/local/share/cuda-11.4/targets/x86_64-
linux/lib:/usr/local/share/cuda-11.4/extras/CUPTI/lib64
```

Pro export cest použíjte script

```
cd Utilities
chmod +x path_export.sh
eval `./path_export.sh`
```

PŘIPOJENÍ NA KAROLÍNU

I Interaktivní práce na Karolíně



Připojte se na Karolínu

```
ssh karolina
```

Vaše PC: Připojte si disk z Karolíny a nakopírujte tam obsah 1. cvičení

```
mkdir /tmp/karolina
sshfs karolina: /tmp/karolina
```

Nastartujte job (pozor, máme jen 8 uzlů). Kompilovat lze i na loginu

o středa – 09.11.

```
qsub -q R1572270 -A DD-21-22 -I -X -l walltime=1:00:0 -l select=1
```

o pátek – 11.11.

```
qsub -q R1572272 -A DD-21-22 -I -X -l walltime=1:0:0 -l select=1
```

Kdykoliv jindy

```
qsub -q qgpu -A DD-21-22 -I -X -l walltime=1:0:0 -l select=1
```

Natáhněte moduly

```
ml CUDA/11.1.1-GCC-10.2.0 Qt5/5.14.2-GCCcore-10.2.0
```

■ Příprava na práci – Implementace CVT, profil Karolína



1. Zkopírujte zdrojové kódy na Barboru

2. Přeložte knihovnu libwb – bude se hodit pro další ukázky

```
cd libwb
make -j
make libwb.a
```

3. Implementaci a testování funkčnosti můžete dělat v CVT, benchmarkování a profilování na Karolíně pomocí skriptu run.pbs

HISTOGRAM

Example 1. Histogram v globální paměti



- Cílem je spočítat četnost výskytu znaků v textovém řetězci s využitím atomických operací nad globální pamětí
- Otevřete soubor template.cu
 - o Doplňte kernel cudaHistogramGlobal
 - Vycházejte z předpokladu, že je pole větší než počet vláken v gridu.
 - Spočtěte histogram pomocí atomických operací nad globální pamětí.
 - o Doplňte funkce histogramGlobal
 - Funkce nejprve nuluje histogram v globální paměti.
 - Následně se volá kernel.

Překlad a spuštěníCVT (bez profil)

```
make
make gen

make run{0-5}
make prof{0-5}
```

Karolína (profil)

```
qsub run.pbs
```

```
make
make prof{0-5}
```

I Example 2. Histogram ve sdílené paměti



 Cílem je spočítat četnost výskytu znaků v textovém řetězci s využitím atomických operací nad globální pamětí

Otevřete soubor template.cu

- o Doplňte kernel cudaHistogramShared
 - Vycházejte z předpokladu, že je pole větší než počet vláken v gridu.
 - Definujte pole sharedHistogram jako externí proměnnou v SM.
 - Vynulujte histogram ve sdílené paměti.
 - Spočtete histogram ve sdílené paměti.
 - Pomocí atomických operací aktualizujte histogram v globální paměti.
- o Doplňte funkce histogramShared
 - Funkce nejprve nuluje histogram v globální paměti.
 - Následně se volá kernel. Zde je nutné specifikovat počet bytů v SM.

Překlad a spuštěníCVT (bez profil)

```
make
make gen

make run{0-5}
make prof{0-5}
```

Karolína (profil)

qsub run.pbs

```
make
make prof{0-5}
```

I Example 3. Redukce pomocí sdílené paměti



- Cílem je spočítat součet hodnot vektoru pomocí redukce ve sdílené paměti
- Otevřete soubor template.cu
 - o Doplňte kernel cudaReduction
 - Vycházejte z předpokladu, že je pole větší než počet vláken v gridu.
 - Definujte pole partialSum jako externí proměnnou v SM.
 - Vynulujte dílčí sumy ve sdílené paměti.
 - Proveďte paralelní redukci nad sdílenou pamětí. Pozor na správně nastavený stride.
 - Pomocí atomických operací aktualizujte výslednou hodnotu v globální Karolína (profil) paměti. Toto provede vždy jedno vláko v blocku.

Překlad a spuštění

CVT (bez profil)

```
make
make gen
make run\{0-5\}
make prof\{0-5\}
```

qsub run.pbs

```
make
make prof\{0-5\}
```

I Example 4. Redukce pomocí registrů



 Cílem je spočítat součet hodnot vektoru pomocí redukce přes registry a warp-synchronního programování

Otevřete soubor template.cu

- o Doplňte kernel cudaReduction
 - Vycházejte z předpokladu, že pole je větší než počet vláken v gridu.
 - Každé vlákno si spočte dílčí sumu v registru.
 - Proveďte paralelní redukci pomocí shufle operací nad registry. Pozor na správně nastavený stride.
 - Pomocí atomických operací aktualizujte výslednou hodnotu v globální paměti. Toto provede vždy jedno vláko v blocku.

Překlad a spuštěníCVT (bez profil)

```
make
make gen

make run{0-5}
make prof{0-5}
```

Karolína (profil)

```
qsub run.pbs
```

```
make
make prof{0-5}
```

Vzorové řešení zveřejníme v pátek